

# SOTA in Computer Vision

Наталья Ханжина  
ML Lab  
CV DL Senior Researcher  
PhD student



Роман Лебедев  
JetBrains Research  
CV DL Intern Researcher  
PhD student

# План лекции

---

- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks

# План лекции

---

- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks


# Short history of computer vision

---

1957	Персептрон Розенблата
1974	Многослойный персептрон и Back propagation algorithm (Rumelhart, Werbos, Galushkin)
1978	Распознавание образов (Gonzalez)
1980	Convolutional NN (Fukushima)
1998	<b>LeNet</b> : Gradient descent for convolutional NN (LeCun et al.)
2006	Deep belief nets (Hinton, Osindero and Teh)
2007	Глубокое обучение (Hinton)

# Modern history of computer vision

- 2012 Архитектура **AlexNet** (Hinton, Krizhevsky, and Sutskever) выиграла ImageNet. С этого началась современная история компьютерного зрения
- 2015 Архитектура **ResNet** превзошла человеческий уровень ошибки на ImageNet




# План лекции

---


- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA модели
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA модели
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA модели
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks

# Базовые слои


- Convolution




- Pooling




- UpSampling



- Dense (fully-connected)



- Dropout



- Batch normalization

$$\hat{x}_i \leftarrow \frac{x_i - \mu_B}{\sqrt{\sigma_B^2 + \epsilon}}$$

// normalize

$$y_i \leftarrow \gamma \hat{x}_i + \beta \equiv \text{BN}_{\gamma, \beta}(x_i)$$

// scale and shift

# Module


---

- Модуль, или блок – структурная единица современных моделей нейросетей
- Каждый модуль – объект или функция  $a = h(x; \theta)$ , которая
  - Имеет настраиваемые параметры( $\theta$ )
  - В качестве аргумента принимает входной сигнал  $x$
  - Возвращает выходное значение  $a$ , пропущенное через функцию активации  $h$
  - Функция активации должна иметь (по крайней мере) производные первого порядка (почти) везде
  - Обучается с помощью **chain rule**
  - Может состоять из базовых слоев (операций)




# Basic classification model

---



# 1x1 convolution

- Свертка 1x1 часто используется в сверточных модулях, она нужна для контроля размерности промежуточных тензоров



- Также известна как Cascaded Cross-Channel pooling (CCCPC)

# Residual block (2015)

- Стакать слои не всегда помогает
- А если добавить не слой, а остаточный сигнал?




Figure 2. Residual learning: a building block.

$\mathcal{H}(x)$  is the true function we want to learn

Let's pretend we want to learn

$$\mathcal{F}(x) := \mathcal{H}(x) - x$$

instead.


The original function is then

$$\mathcal{F}(x) + x$$


- ResNets

# Depth-wise Separable Convolution (2017)

Conv2d




Separable Conv2d




- В три раза меньше обучаемых параметров  $\min$
- MobileNet, Xception

# Residual Inverted block (2018)

Residual block




Inverted Residual block




- Меньше параметров
- MobileNetV2, EfficientNet

# Independent-Component (IC) layer (2019)

BatchNorm conv  
block




IC block



- +3% accuracy на CIFAR100
- Tested on ResNet


# Squeeze-and-Excitation block (2017)

ResNet module




- Attention для картинок
- 25% boost on ImageNet
- SENets, EfficientNet DeepSEED...

SE-ResNet module




# ResNeXt (2016)

ResNet block



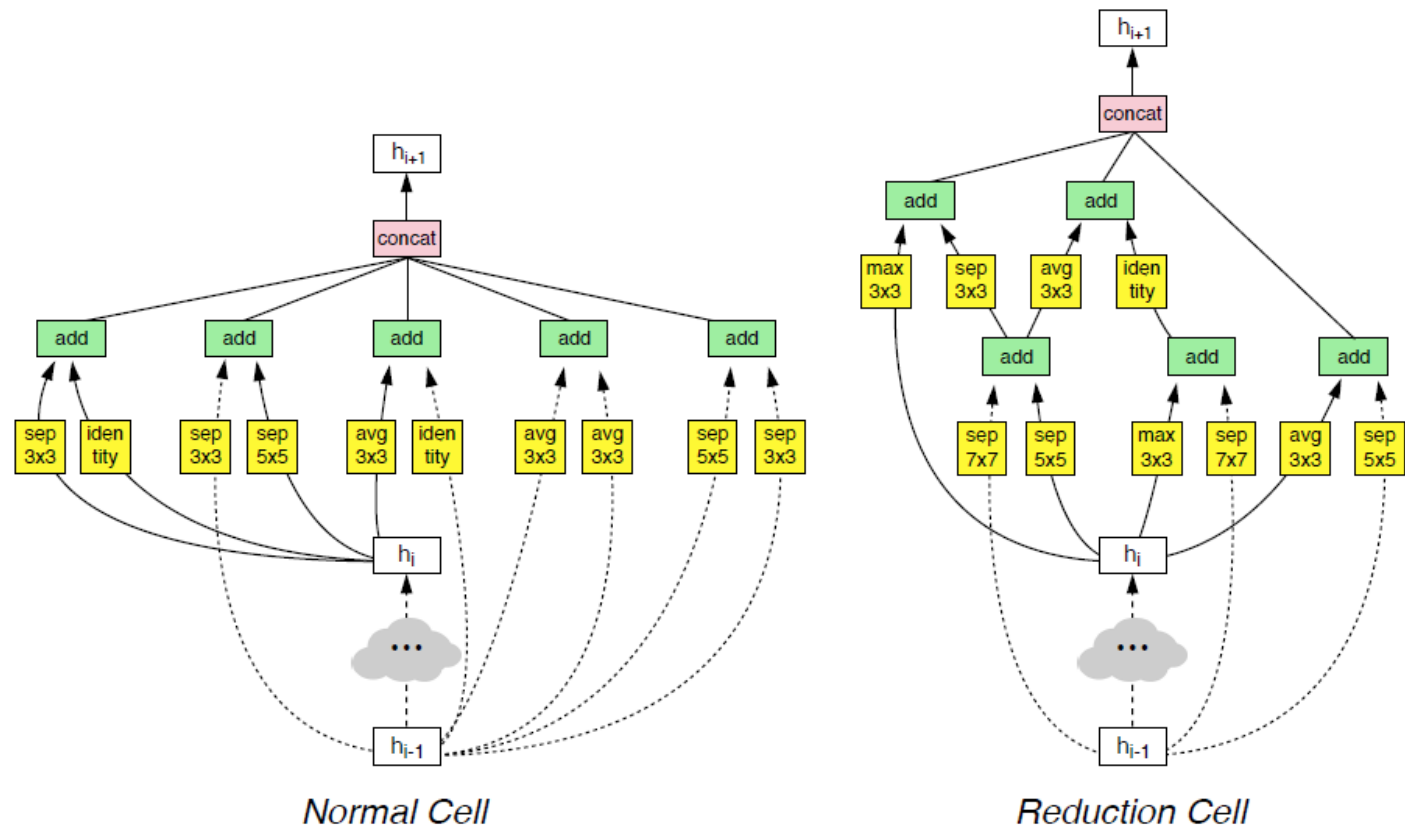
ResNeXt shortcut



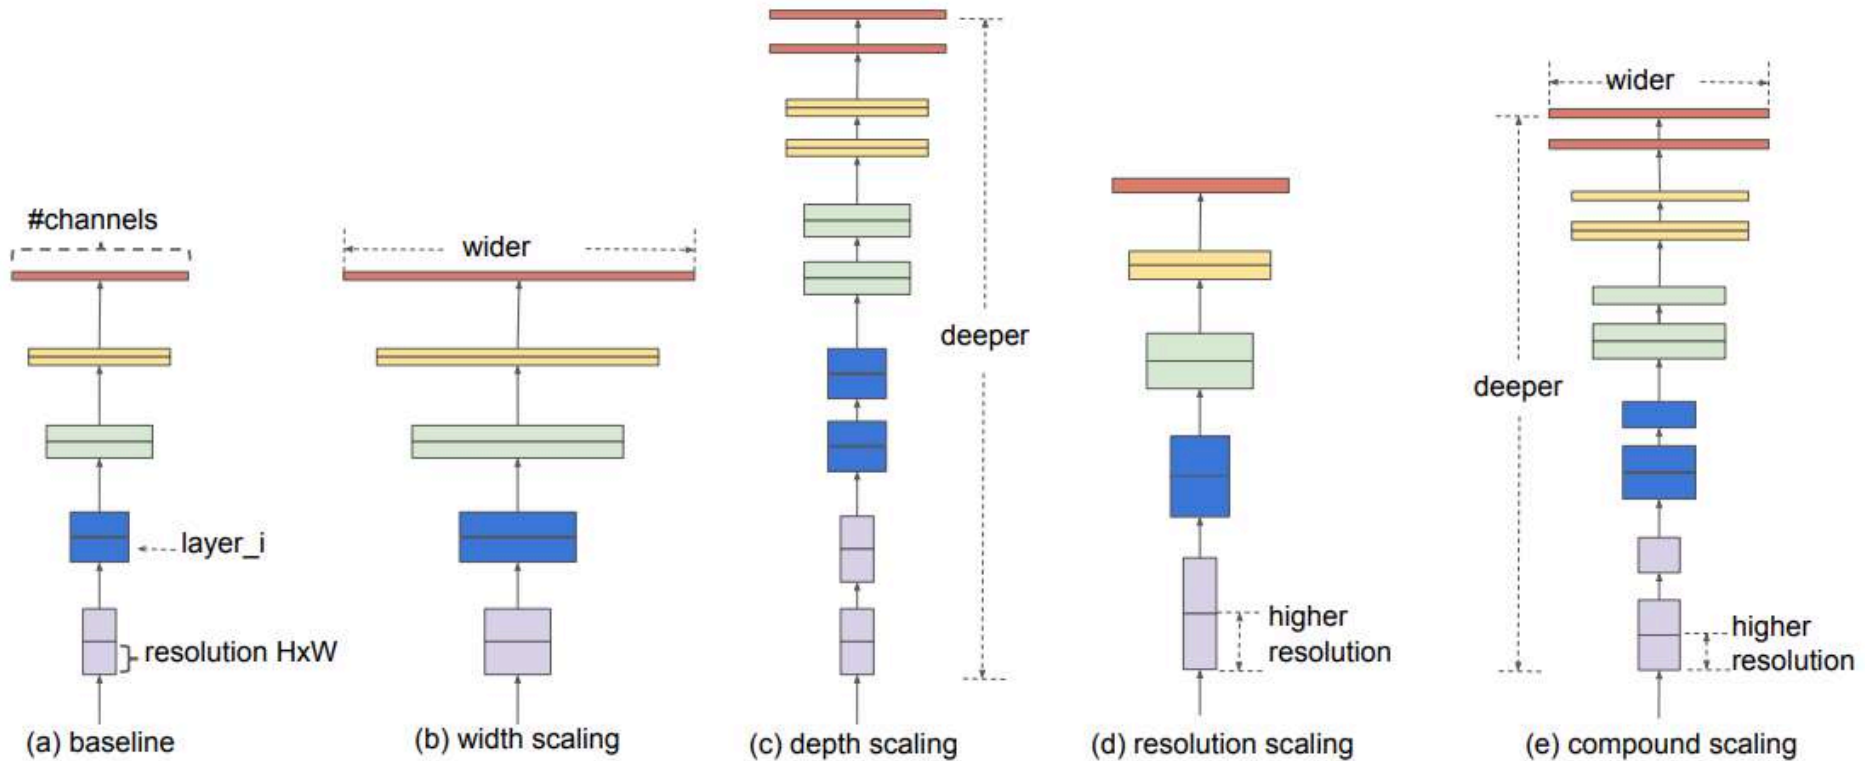


# NASNet (2018)

- Найдена с помощью AutoML
- Использует ScheduledDropPath
- 82,7% accuracy on ImageNet



# EfficientNet (2019)




- Top accuracy on ImageNet (84,4%)
- Использует Compound model scaling coefficient  $\phi$

# Классификация: SOTA model zoo

---


- Классификация:
  - [EfficientNet](#)
  - [AmoebaNet](#)
  - [ResNeXt](#)
  - [NASNet](#)
  - [SENet](#)
  - [Inception-ResNet](#)
  - [Xception](#)
  - [MobileNetV2](#)

# Network comparison

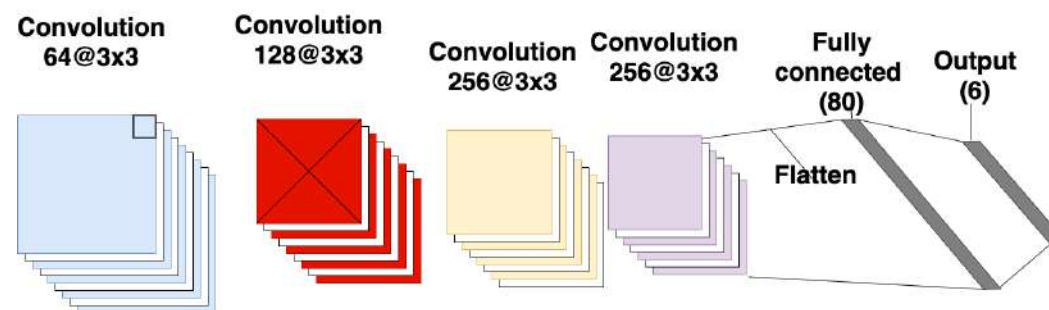


# Регуляризация


## Dropout (2014)




## DropLayer (2016)



## DropChannel (2018)



## DropBlock (2015)



# Benchmarks for classification

---

ImageNet(ILSVRC)	1000 classes	<a href="#">data</a>
CIFAR	100/10 classes	<a href="#">data</a>
MNIST	10 classes	<a href="#">data</a>
FashionMNIST	10 classes	<a href="#">data</a>
Food-11	11 classes	<a href="#">data</a>
KITTI Vision Benchmark Suite	8 classes	<a href="#">data</a>
Visual Object Classes 2012 (VOC12)	20 classes	<a href="#">data</a>
Common Objects in Context (COCO)	80 classes	<a href="#">data</a>

# План лекции


---

- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks


# Basic detection model




Input image



Feature  
extractor



FPN



FC

Bbox

Class



# Quality Assessment and Metrics

- mean average precision (mAP)

- Для каждого класса  $c_i$  вычислить average precision  $ap_i = AP(c_i)$
- Посчитать среднее по всем  $ap_i$  значениям для каждого класса

- intersection over union (IoU)

- Каждый bounding box (результат детекции) обладает определенной уверенностью предсказания (confidence)
- Оценивается близость *predicted bboxes* с *ground truth bboxes* как истинные/ложные срабатывания по уровню их пересечения
- Чтобы считаться корректным обнаружением (т. е. истинно положительным), площадь пересечения  $a_{ovl}$  между *predicted bounding box*  $BB_p$  и *ground truth bounding box*  $BB_{gt}$  должна быть больше 0,5 согласно формуле


$$area_{ovl} = \frac{area(BB_p \cap BB_{gt})}{area(BB_p \cup BB_{gt})} \quad (1)$$

$area_{ovl}$  часто называют *intersection over union* (IoU)


# Quality Assessment and Metrics

IoU


$$\text{IoU} = \frac{\text{Area of Overlap}}{\text{Area of Union}}$$



IoU = 0.5



IoU = 0.7



IoU = 0.9

## Generalized IoU (2019)

---

**Algorithm 1:** Generalized Intersection over Union

---

**input** : Two arbitrary convex shapes:  $A, B \subseteq \mathbb{S} \in \mathbb{R}^n$

**output:**  $GIoU$

1 For  $A$  and  $B$ , find the smallest enclosing convex object  $C$ ,  
where  $C \subseteq \mathbb{S} \in \mathbb{R}^n$

2  $IoU = \frac{|A \cap B|}{|A \cup B|}$

3  $GIoU = IoU - \frac{|C \setminus (A \cup B)|}{|C|}$

---

# Quality Assessment

- Non-Maximum Suppression (NMS):

```
# code is taken from https://www.pyimagesearch.com/2014/11/17/non-maximum-suppression-object-detection-python/
```

```
# loop over all indexes in the indexes list
```

```
for pos in xrange(0, last):
```

```
# grab the current index
```

```
j = idxs[pos]
```

```
# find the largest (x, y) coordinates for the start of
```

```
# the bounding box and the smallest (x, y) coordinates
```

```
# for the end of the bounding box
```

```
xx1 = max(x1[i], x1[j])
```

```
yy1 = max(y1[i], y1[j])
```

```
xx2 = min(x2[i], x2[j])
```

```
yy2 = min(y2[i], y2[j])
```

```
# compute the width and height of the bounding box
```

```
w = max(0, xx2 - xx1 + 1)
```

```
h = max(0, yy2 - yy1 + 1)
```

```
# compute the ratio of overlap between the computed
```

```
# bounding box and the bounding box in the area list
```

```
overlap = float(w * h) / area[j]
```

```
# if there is sufficient overlap, suppress the
```

```
# current bounding box
```

```
if overlap > overlapThresh:
```

```
suppress.append(pos)
```

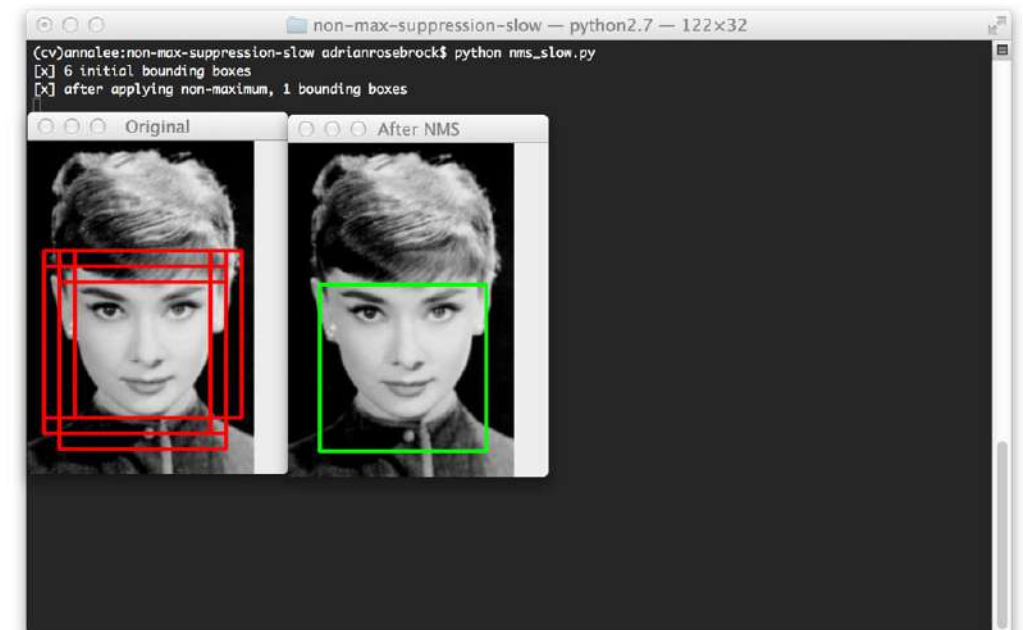
```
# delete all indexes from the index list that are in the
```

```
# suppression list
```







```
idxs = np.delete(idxs, suppress)
```

```
# return only the bounding boxes that were picked
```

```
return boxes[pick]
```

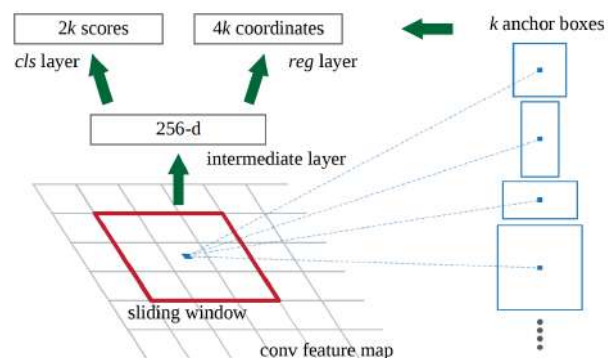


# Feature pyramid networks




# Model zoo


- Anchor-based:



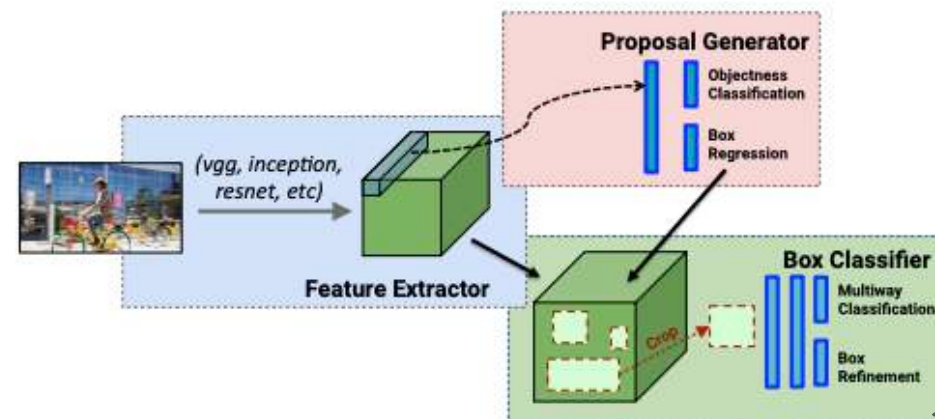
- One-shot:



- Key-point-based:



- Two-shot:



# Model zoo

---

- Anchor-based:
  - [EfficientDet](#)
  - [YOLO v4](#)
  - [RetinaNet](#)
  - [SSD](#) (on MobileNet v2)
- One-shot:
  - [YOLO v4](#)
  - [RetinaNet](#)
  - [RPN](#)
  - [FCOS](#)
  - [SSD](#)
- Key-point-based:
  - [CornerNet](#)
  - [CenterNet](#)
  - [FCOS](#)
- Two-shot:
  - [Faster R-CNN](#)
  - [R-FCN](#)

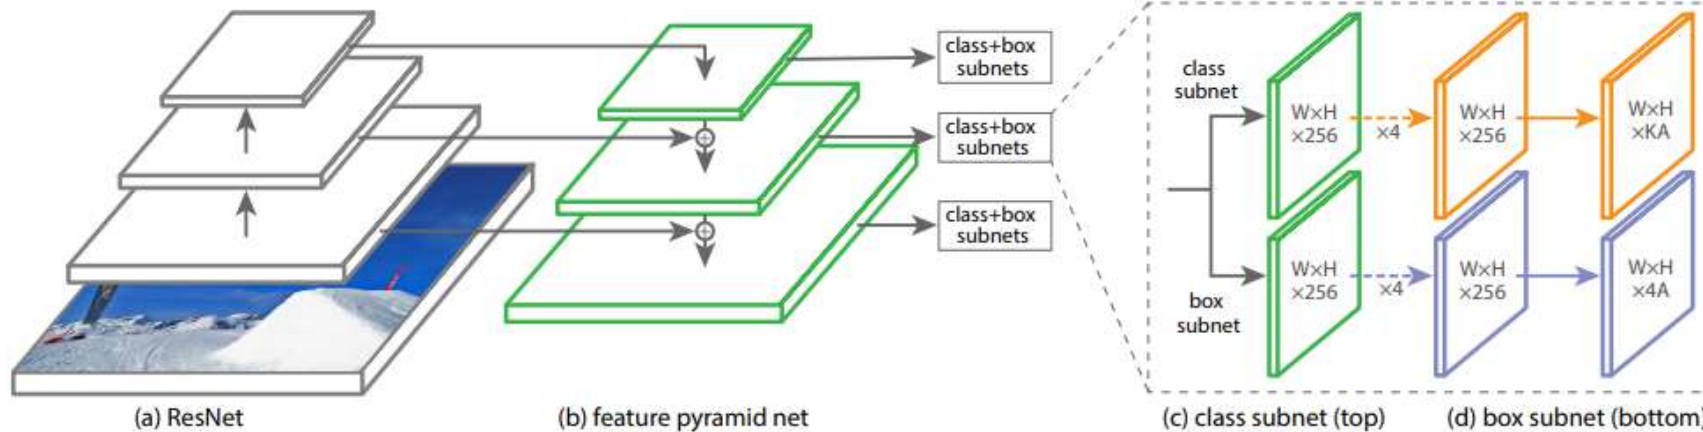



# RetinaNet (2017)


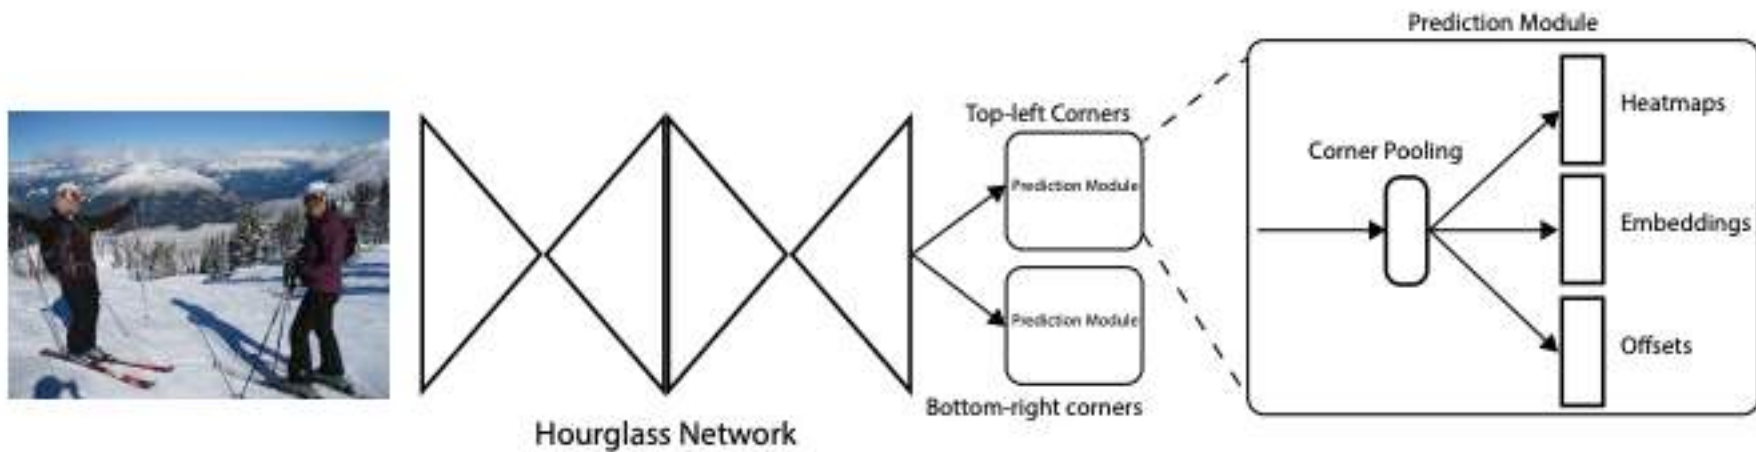
- Использует Focal loss
- Использует FPN

$$\text{CE}(p, y) = \begin{cases} -\log(p) & \text{if } y = 1 \\ -\log(1 - p) & \text{otherwise.} \end{cases}$$

$$\text{FL}(p, y) = \begin{cases} -\alpha(1 - p)^\gamma \log p, & \text{if } y = 1 \\ -p^\gamma \log(1 - p), & \text{otherwise.} \end{cases}$$



# CornerNet (2019)




	AP	AP <sup>50</sup>	AP <sup>60</sup>	AP <sup>70</sup>	AP <sup>80</sup>	AP <sup>90</sup>
RetinaNet (Lin et al., 2017)	39.8	59.5	55.6	48.2	36.4	15.1
Cascade R-CNN (Cai and Vasconcelos, 2017)	38.9	57.8	53.4	46.9	35.8	15.8
Cascade R-CNN + IoU Net (Jiang et al., 2018)	41.4	59.3	55.3	49.6	39.4	19.5
CornerNet	40.6	56.1	52.0	46.8	38.8	23.4




# FCOS (2019)

- Предсказывает вектор  $(l, t, r, b)$  удаленности точки от для каждого пикселя
- Отказ от кандидатов
- Проблема пересечения классов
- Для решения предсказываем класс наименьшего размера



# EfficientDet (2020)



- Единый масштабирующий коэффициент  $\phi$
- Сгенерированные архитектуры EfficientDet превосходят по скорости сравнимые по точности архитектуры

	Input size $R_{input}$	Backbone Network	BiFPN #channels $W_{bifpn}$	BiFPN #layers $D_{bifpn}$	Box/class #layers $D_{class}$
D0 ( $\phi = 0$ )	512	B0	64	3	3
D1 ( $\phi = 1$ )	640	B1	88	4	3
D2 ( $\phi = 2$ )	768	B2	112	5	3
D3 ( $\phi = 3$ )	896	B3	160	6	4
D4 ( $\phi = 4$ )	1024	B4	224	7	4
D5 ( $\phi = 5$ )	1280	B5	288	7	4
D6 ( $\phi = 6$ )	1280	B6	384	8	5
D7 ( $\phi = 7$ )	1536	B6	384	8	5
D7x	1536	B7	384	8	5

# Anchor vs anchor-free detectors

- [Авторы](#) добавили главные фичи FCOS в RetinaNet

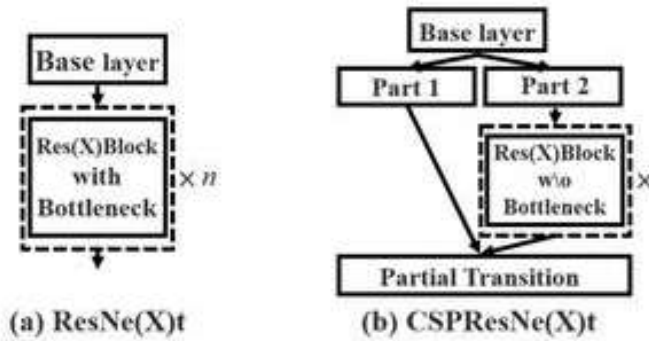
Inconsistency	FCOS	RetinaNet (#A=1)					
GroupNorm	✓	✓	✓	✓	✓	✓	✓
GIoU Loss	✓		✓	✓	✓	✓	✓
In GT Box	✓			✓	✓	✓	✓
Centerness	✓				✓	✓	✓
Scalar	✓						✓
AP (%)	37.8	32.5	33.4	34.9	35.3	36.8	37.0

- Оказалось, что их точность стала сравнима (разница 0,8%)
- Таким образом, оба подхода к детекции объектов достигают одинаковой точности при равных условиях

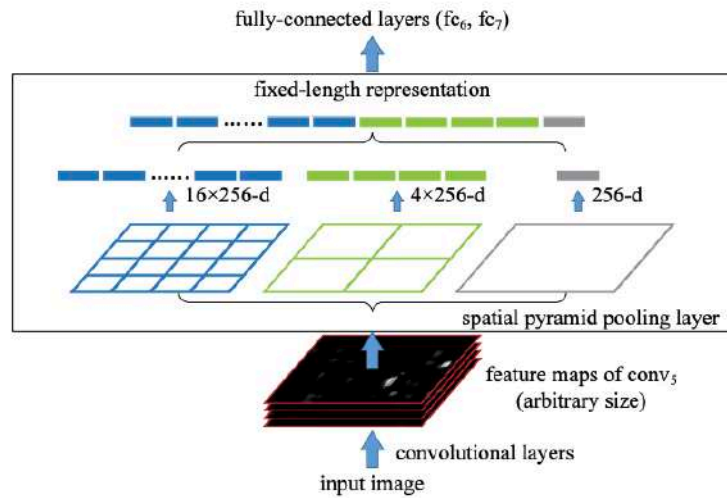
Classification	Regression	Box	Point
	Intersection over Union	37.0	36.9
	Spatial and Scale Constraint	37.8	37.8

# YOLOv4 (2020)


- CSPDarknet backbone



- SPP (Spatial Pyramid Pooling)



- Modified PANet as FPN



- YOLOv3 head
- Modified Spatial attention module
- Mosaic Augmentation
- Self-adversarial training

# Public Datasets for detection

ICDAR	2013-2019	OCR	<a href="#">paper</a>	<a href="#">data</a>
COCO-Text	2016	OCR	<a href="#">paper</a>	<a href="#">data</a>
SynthText	2016	OCR	<a href="#">paper</a>	<a href="#">data</a>
LUNA16	2016	CT/lung	<a href="#">paper</a>	<a href="#">data</a>
SUN RGB-D	2015	indoor	<a href="#">paper</a>	<a href="#">data</a>
Common Objects in Context (COCO)	2014	general	<a href="#">paper</a>	<a href="#">data</a>
Oxford RoboCar Dataset	2014	street	<a href="#">paper</a>	<a href="#">data</a>
KITTI Vision Benchmark Suite	2012	street	<a href="#">paper</a>	<a href="#">data</a>
Visual Object Classes 2012 (VOC12)	2012	street	<a href="#">[1]</a> <a href="#">[2]</a>	<a href="#">data</a>
LIDC-IDRI	2011	CT/lung	<a href="#">paper</a>	<a href="#">data</a>
Caltech Pedestrian Detection Benchmark	2009	street	<a href="#">[1]</a> <a href="#">[2]</a>	<a href="#">data</a>



# План лекции

---

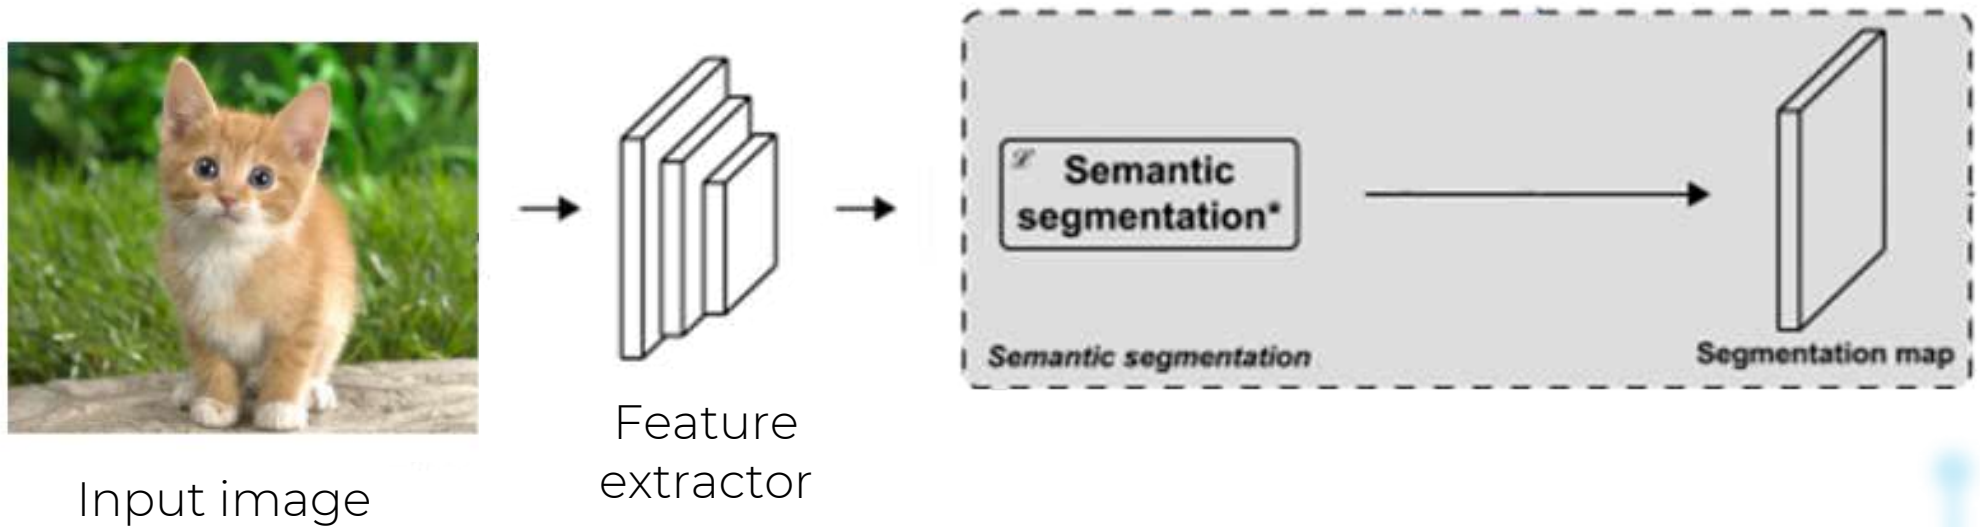
- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks



# Semantic segmentation



# Basic semantic segmentation model







# Model zoo

---



- Семантическая сегментация:
  - [HRNet](#)
  - [PSPNet](#)
  - [UNet++](#)
  - [DeepLabV3](#)
  - [Mask R-CNN](#)

# HRNet (2020)

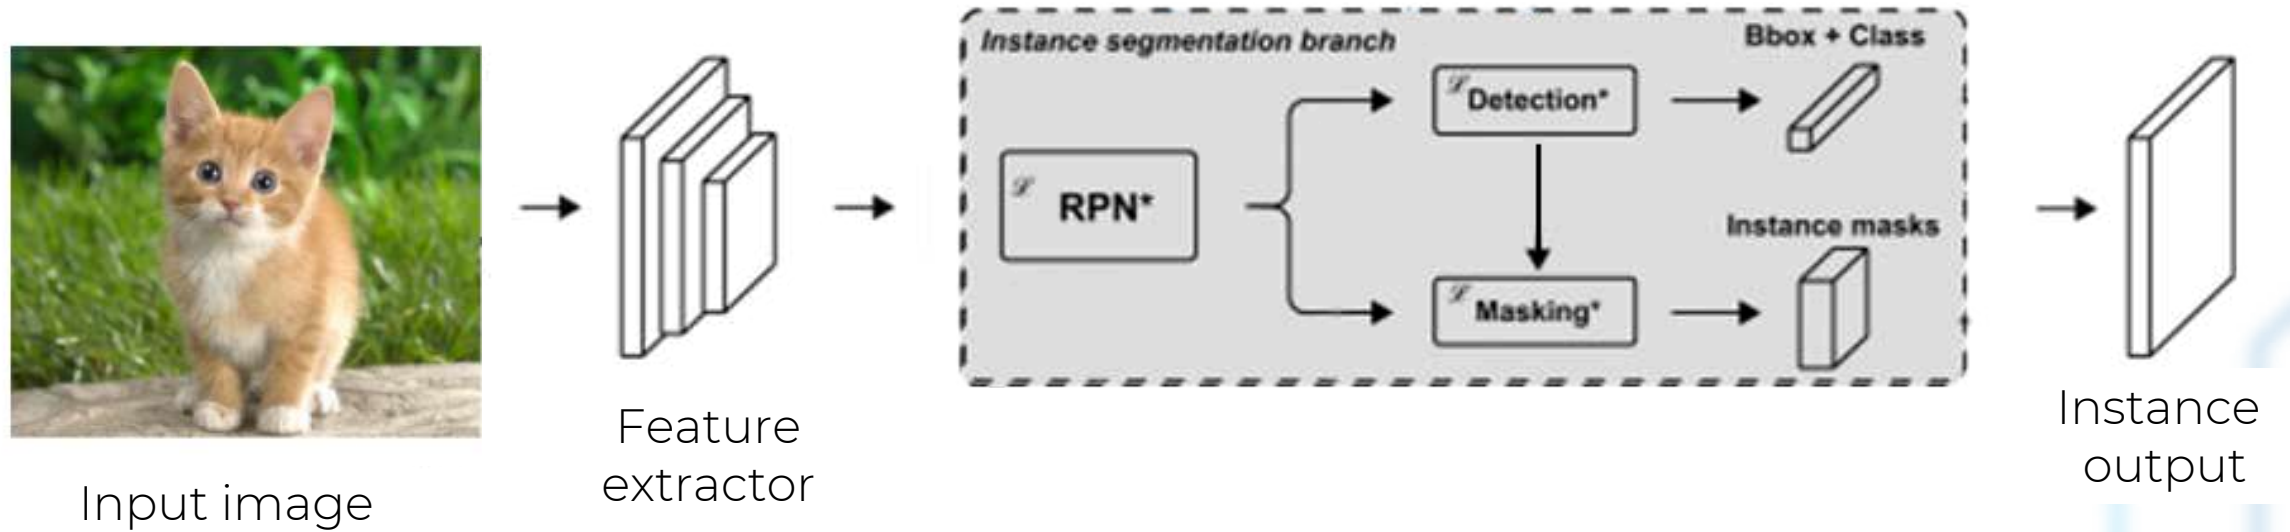
- Построение признаков высокого разрешения



# Instance segmentation



# Basic instance segmentation model





# Mask R-CNN (2017)

Results on COCO test images using ResNet-101-FPN at 5 fps.



# SOTA model zoo

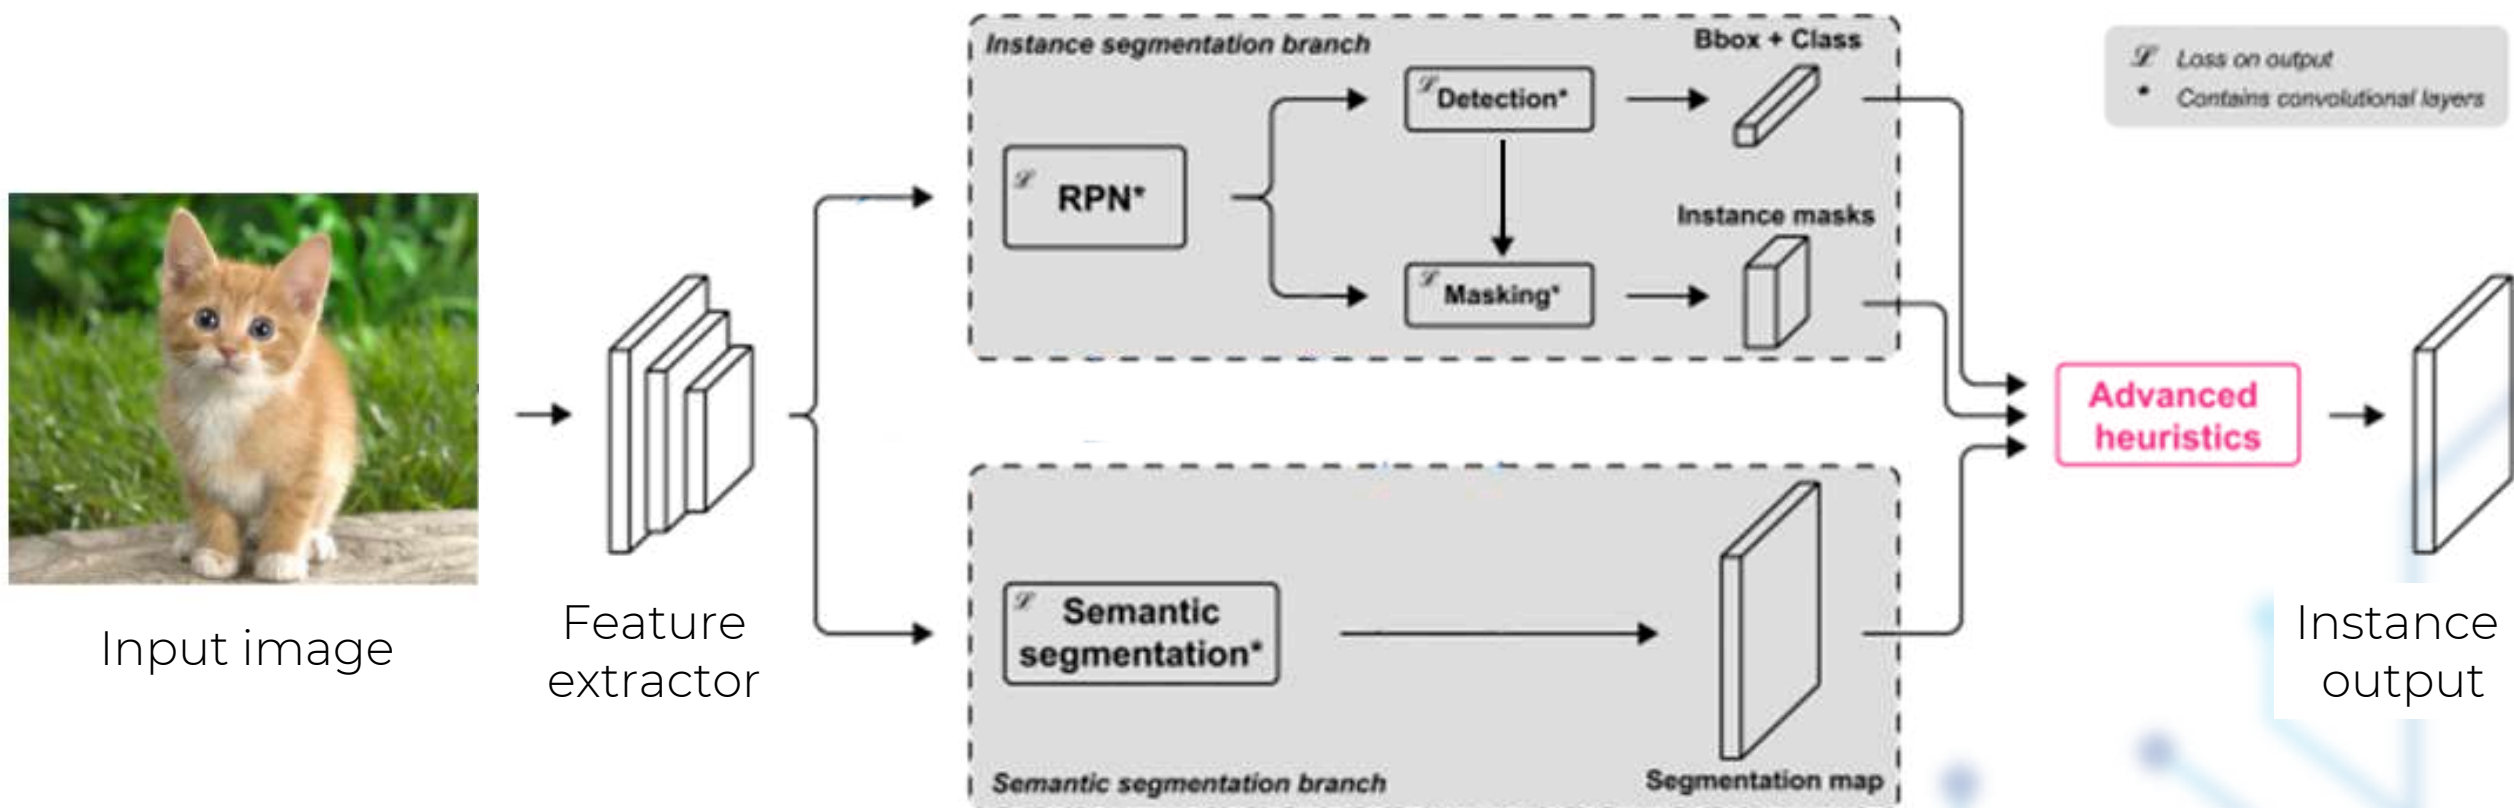
---

- Инстанс сегментация:
  - [Mask R-CNN](#)
  - Detectron (see model zoo)
  - Detectron2 (see model zoo)

# Panoptic segmentation



# Basic panoptic segmentation model






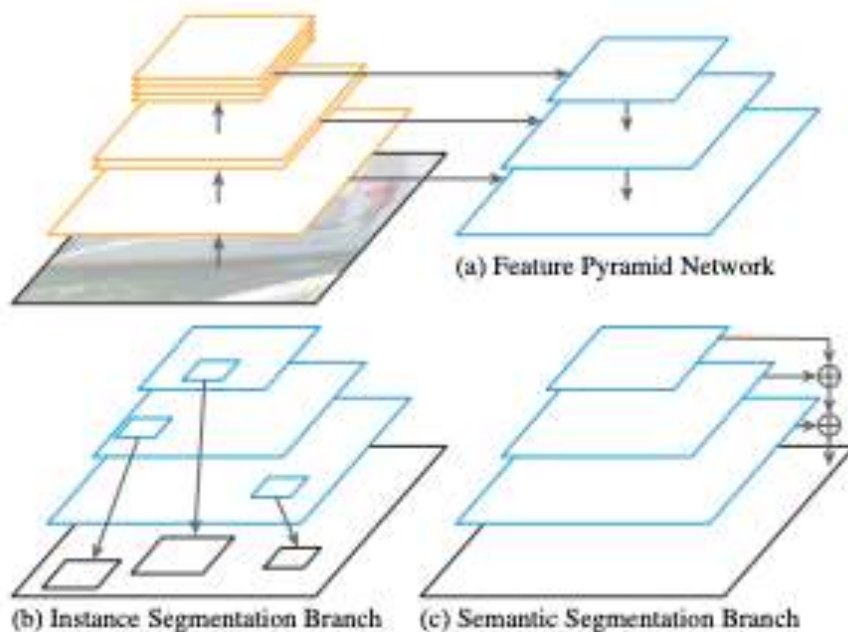
# Model zoo

---

- Паноптическая сегментация:
  - [Panoptic FPN](#)
  - [CenterMask](#)
  - [AdaptIS \(Adaptive Instance Segmentation\)](#)

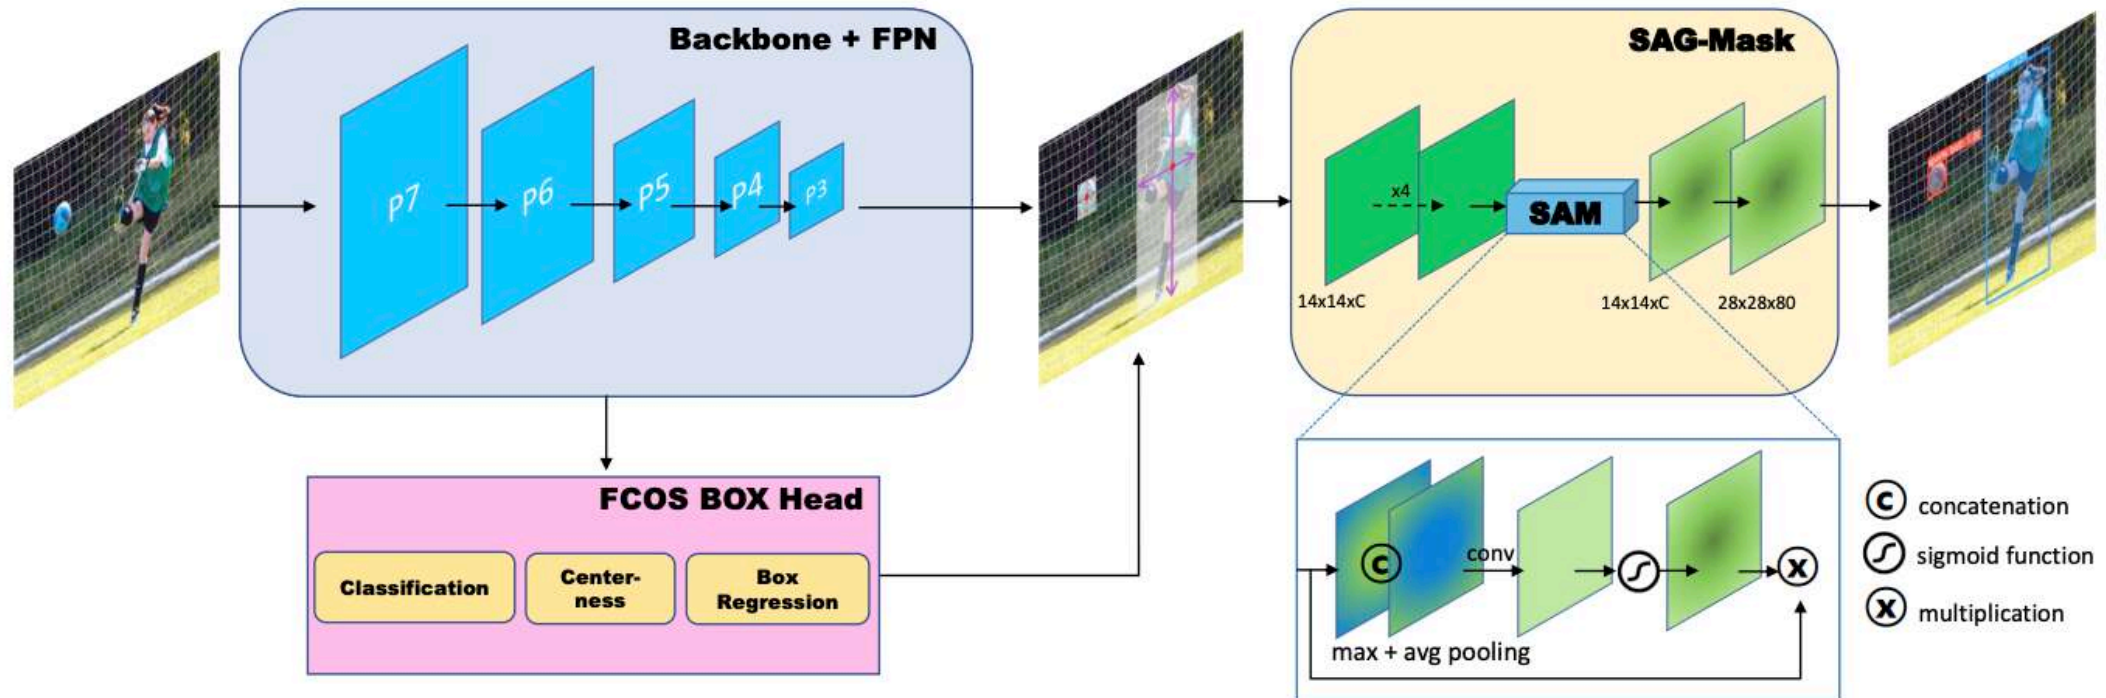
# Panoptic Feature Pyramid Networks (2019)

Mask R-CNN, дополненная веткой семантической сегментации



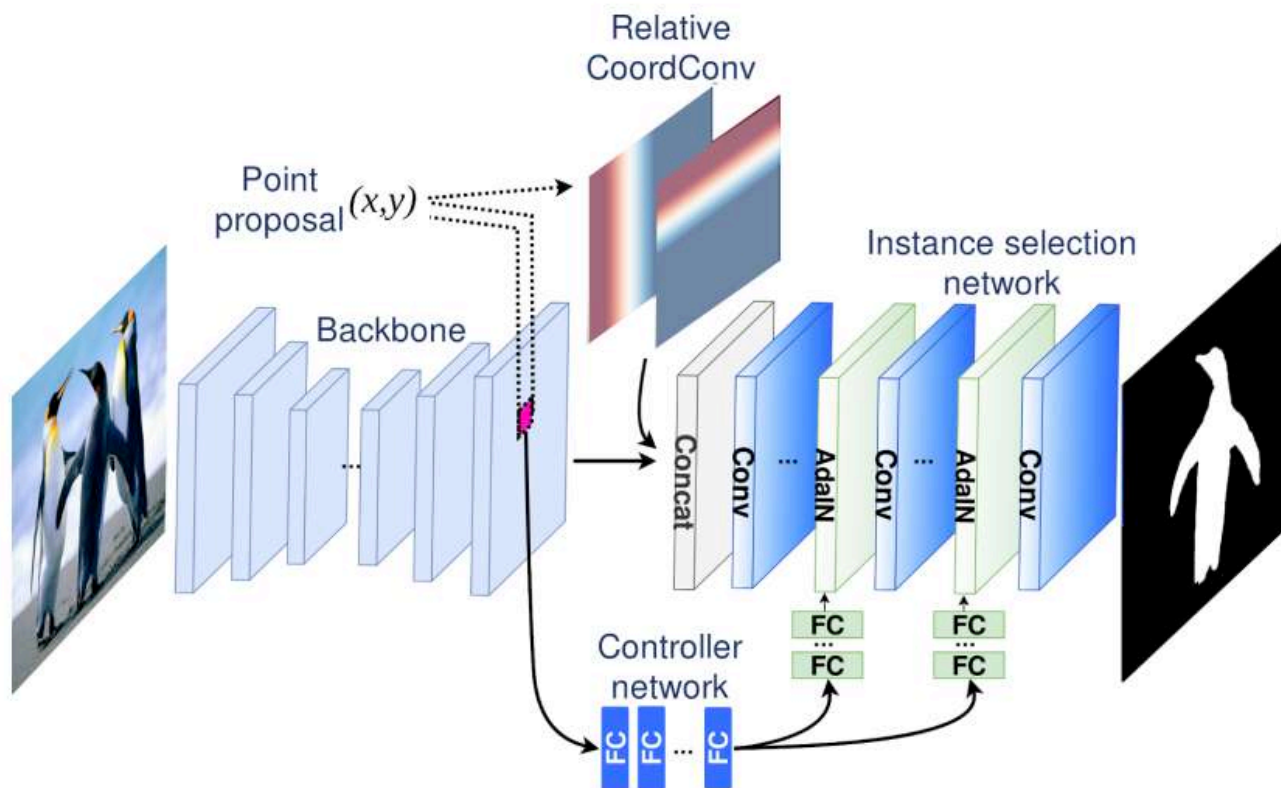
# CenterMask (2020)

- FCOS + Mask R-CNN
- Для каждого объекта генерируется его маска



# AdaptIS (2019)

- Использует Adaptive Instance Normalization (AdaIN)
- AdaIN – управляющая сеть



# Public Datasets for segmentation

BRaTS	2012-2020	MRI/brain	<a href="#">paper</a>	<a href="#">data</a>
Inria Aerial Image Labeling	2017	UAV	<a href="#">paper</a>	<a href="#">data</a>
DAVIS Challenge	2017	general	<a href="#">paper</a>	<a href="#">data</a>
Mapillary Vistas	2017	street	<a href="#">paper</a>	<a href="#">data</a>
ADE20K	2016	indoor	<a href="#">paper</a>	<a href="#">data</a>
SYNTHIA	2016	street	<a href="#">paper</a>	<a href="#">data</a>
SpaceNet	2016	UAV	N/A	<a href="#">data</a>
Playing for Data	2016	street	<a href="#">paper</a>	<a href="#">data</a>
SUN RGB-D	2015	indoor	<a href="#">paper</a>	<a href="#">data</a>
Cityscapes	2015	street	<a href="#">paper</a>	<a href="#">data</a>
Common Objects in Context (COCO)	2014	general	<a href="#">paper</a>	<a href="#">data</a>
Oxford RoboCar Dataset	2014	street	<a href="#">paper</a>	<a href="#">data</a>
KITTI Vision Benchmark Suite	2012	street	<a href="#">paper</a>	<a href="#">data</a>
Visual Object Classes 2012 (VOC12)	2012	street	<a href="#">[1]</a> <a href="#">[2]</a>	<a href="#">data</a>
NYU Depth Dataset V2	2012	indoor	<a href="#">paper</a>	<a href="#">data</a>
CamVid: Motion-based Segmentation	2008	street	<a href="#">paper</a>	<a href="#">data</a>



# План лекции

---

- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks



# Practical tips: Bag of freebies

- SOTA Augmentations:
  - Mixup



- Cutout



- CutMix (2 images)




- **Mosaic (4 images)**





# Practical tips: Bag of freebies

- Test-time Augmentation (TTA)
  - Позволяет повысить точность на  $\sim 3\%$
  - Увеличивает время inference



# Practical tips: Bag of specials

---


- [ATSS \(Adaptive training sample selection\)](#)
- [Self-adversarial training](#)
- [Uncertainty estimation with MC Dropout](#)

# План лекции

---

- Краткая история компьютерного зрения
- Классификация изображений
  - Модули
  - SOTA model zoo
  - Регуляризация
  - Наборы данных
- Детекция изображений
  - Модули
  - Виды детекции и SOTA model zoo
  - Losses
  - Метрики
  - Наборы данных
- Сегментация
  - Виды сегментации
  - Модули
  - SOTA model zoo
  - Метрики
  - Наборы данных
- Practical tips
  - Bag of freebies
  - Bag of specials
- SOTA frameworks

# Common trends



# Low-level frameworks



- › tf.errors
- › tf.estimator
- › tf.experimental 🧪
- › tf.feature\_column
- › tf.graph\_util
- › tf.image
- › tf.io
- › tf.keras
- › tf.linalg
- › tf.lite
- › tf.lookup
- › tf.math
- › tf.mixed\_precision
- › tf.mlir
- › tf.nest
- › tf.nn
- › tf.quantization



- Низкоуровневый, но
- TFLearn, TFLite etc
- Много шаблонного кода
- Подходит для продакшн
- Визуализация Tensorboard
- Tensorflow Serving
- Quick Tutorial



- Проще и
- FastAI, Lightning advanced stuff
- Много готовых модулей
- Подходит для прототипирования
- Подходит для ризерча
- Визуализация visdom
- Flask
- Quick Tutorial

# Catalyst & Pytorch Lightning

Catalyst

VS

```
21 # model runner
22 runner = SupervisedRunner()
23
24 # model training
25 runner.train(
26     model=model,
27     criterion=criterion,
28     optimizer=optimizer,
29     scheduler=scheduler,
30     loaders=loaders,
31     callbacks=[
32         PrecisionCallback(),
33         EarlyStoppingCallback()
34     ],
35     logdir=logdir,
36     n_epochs=n_epochs,
37     verbose=True
38 )
39
```

```
1 import argparse
2
3 import torch
4 import torch.nn as nn
5 import torch.nn.parallel
6 import torch.optim
7 import torch.utils.data
8 import torchvision.transforms as transforms
9 import torchvision.datasets as datasets
10 import torchvision.models as models
11
12 # experiment setup
13 logdir = "./logdir"
14 n_epochs = 42
15 args = ...
16
17 # data
18 loaders = {'train': train_loader, 'valid': test_loader}
19
20 use_cuda = not args.no_cuda and torch.cuda.is_available()
21 device = torch.device("cuda" if use_cuda else "cpu")
22
23 # model, criterion, optimizer
24 model = Net()
25
26 if args.gpu is not None:
27     torch.cuda.set_device(args.gpu)
28     model = model.cuda(args.gpu)
29 else:
30     # DataParallel will divide and allocate batch_size to all available GPUs
31     model = torch.nn.DataParallel(model).cuda()
32
33 # define loss function (criterion) and optimizer
34 criterion = nn.CrossEntropyLoss().cuda(args.gpu)
35
36 optimizer = torch.optim.SGD(
37     model.parameters(), args.lr,
38     momentum=args.momentum,
39     weight_decay=args.weight_decay)
40
41 for epoch in range(args.start_epoch, args.epochs):
42     adjust_learning_rate(optimizer, epoch, args)
43
44     # train for one epoch
45     train(train_loader, model, criterion, optimizer, epoch, args)
46
47     # evaluate on validation set
48     acc1 = validate(val_loader, model, criterion, args)
49
50     # remember best acc1 and save checkpoint
51     is_best = acc1 > best_acc1
52     best_acc1 = max(acc1, best_acc1)
53
54     save_checkpoint({
55         'epoch': epoch + 1,
56         'arch': args.arch,
57         'state_dict': model.state_dict(),
58         'best_acc1': best_acc1,
59         'optimizer': optimizer.state_dict(),
60     }, is_best)
61
62
```

```
63
64
65 def train(train_loader, model, criterion, optimizer, epoch, args):
66     batch_time = AverageMeter()
67     data_time = AverageMeter()
68     losses = AverageMeter()
69     top1 = AverageMeter()
70     top5 = AverageMeter()
71
72     # switch to train mode
73     model.train()
74
75     end = time.time()
76     for i, (input, target) in enumerate(train_loader):
77         # measure data loading time
78         data_time.update(time.time() - end)
79
80         if args.gpu is not None:
81             input = input.cuda(args.gpu, non_blocking=True)
82             target = target.cuda(args.gpu, non_blocking=True)
83
84         # compute output
85         output = model(input)
86         loss = criterion(output, target)
87
88         # measure accuracy and record loss
89         acc1, acc5 = accuracy(output, target, topk=(1, 5))
90         losses.update(loss.item(), input.size())
91         top1.update(acc1[0], input.size())
92         top5.update(acc5[0], input.size())
93
94         # compute gradient and do SGD step
95         optimizer.zero_grad()
96         loss.backward()
97         optimizer.step()
98
99         # measure elapsed time
100         batch_time.update(time.time() - end)
101         end = time.time()
102
103         if i % args.print_freq == 0:
104             print('Epoch: [{0}][{1}/{2}]\t'
105                   '\tTime (batch_time.val:.3f) (batch_time.avg:.3f)\t'
106                   '\tData (data_time.val:.3f) (data_time.avg:.3f)\t'
107                   '\tLoss (loss.val:.4f) (loss.avg:.4f)\t'
108                   '\tAcc@1 (top1.val:.3f) (top1.avg:.3f)\t'
109                   '\tAcc@5 (top5.val:.3f) (top5.avg:.3f)'.format(
110                     epoch, i, len(train_loader), batch_time=batch_time,
111                     data_time=data_time, loss=losses, top1=top1, top5=top5))
112
113 def validate(val_loader, model, criterion, args):
114     batch_time = AverageMeter()
115     losses = AverageMeter()
116     top1 = AverageMeter()
117     top5 = AverageMeter()
118
119     # switch to evaluate mode
120     model.eval()
121
122     with torch.no_grad():
123         end = time.time()
124         for i, (input, target) in enumerate(val_loader):
125             if args.gpu is not None:
126                 input = input.cuda(args.gpu, non_blocking=True)
127                 target = target.cuda(args.gpu, non_blocking=True)
128
129             # compute output
130             output = model(input)
131             loss = criterion(output, target)
132
133             # measure accuracy and record loss
134             acc1, acc5 = accuracy(output, target, topk=(1, 5))
135             losses.update(loss.item(), input.size())
136             top1.update(acc1[0], input.size())
137             top5.update(acc5[0], input.size())
138
139             # measure elapsed time
140             batch_time.update(time.time() - end)
141             end = time.time()
142
143             if i % args.print_freq == 0:
144                 print('Test: [{0}][{1}/{2}]\t'
145                       '\tTime (batch_time.val:.3f) (batch_time.avg:.3f)\t'
146                       '\tLoss (loss.val:.4f) (loss.avg:.4f)\t'
147                       '\tAcc@1 (top1.val:.3f) (top1.avg:.3f)\t'
148                       '\tAcc@5 (top5.val:.3f) (top5.avg:.3f)'.format(
149                         i, len(val_loader), batch_time=batch_time, loss=losses,
150                         top1=top1, top5=top5))
151
152         print(' * Acc@1 (top1.avg:.3f) Acc@5 (top5.avg:.3f)'
153               '.format(top1.avg, top5.avg))
154
155     return top1.avg
156
157
158 def save_checkpoint(state, is_best, filename='checkpoint.pth.tar'):
159     torch.save(state, filename)
160     if is_best:
161         shutil.copyfile(filename, 'model_best.pth.tar')
162
163
164 class AverageMeter(object):
165     """Computes and stores the average and current value"""
166     def __init__(self):
167         self.reset()
168
169     def reset(self):
170         self.val = 0
171         self.avg = 0
172         self.sum = 0
173         self.count = 0
174
175     def update(self, val, n=1):
176         self.val = val
177         self.sum += val * n
178         self.count += n
179         self.avg = self.sum / self.count
180
181
182 def adjust_learning_rate(optimizer, epoch, args):
183     """Sets the learning rate to the initial LR decayed by 10 every 30 epochs"""
184     lr = args.lr * (0.1 ** (epoch // 30))
185     for param_group in optimizer.param_groups:
186         param_group['lr'] = lr
187
188
189 def accuracy(output, target, topk=(1,)):
190     """Computes the accuracy over the k top predictions for the specified values of k"""
191     with torch.no_grad():
192         batch_size = target.size(0)
193         _, grad = output.topk(maxk, 1, True, True)
194         pred = grad.t()
195         correct = pred.eq(target.view(1, -1).expand_as(pred))
196
197     res = []
198     for k in topk:
199         correct_k = correct[:k].view(-1).float().sum(0, keepdim=True)
200         res.append(correct_k.mul_(100.0 / batch_size))
201     return res

```

200+ lines!



# Detection frameworks

## MMDetection

### MMDetection


News: We released the technical report on [ArXiv](#).

Documentation: <https://mmdetection.readthedocs.io/>

### Introduction

The master branch works with **PyTorch 1.1 to 1.4**.

mmdetection is an open source object detection toolbox based on PyTorch. It is a part of the open-r by [Multimedia Laboratory, CUHK](#).



## Detectron



# Segmentation frameworks

## MMSegmentation



Documentation: <https://mmssegmentation.readthedocs.io/>

**Introduction**

MMSegmentation is an open source semantic segmentation toolbox based on PyTorch. It is a part of the OpenMMLab project.

The master branch works with **PyTorch 1.3 to 1.6**.



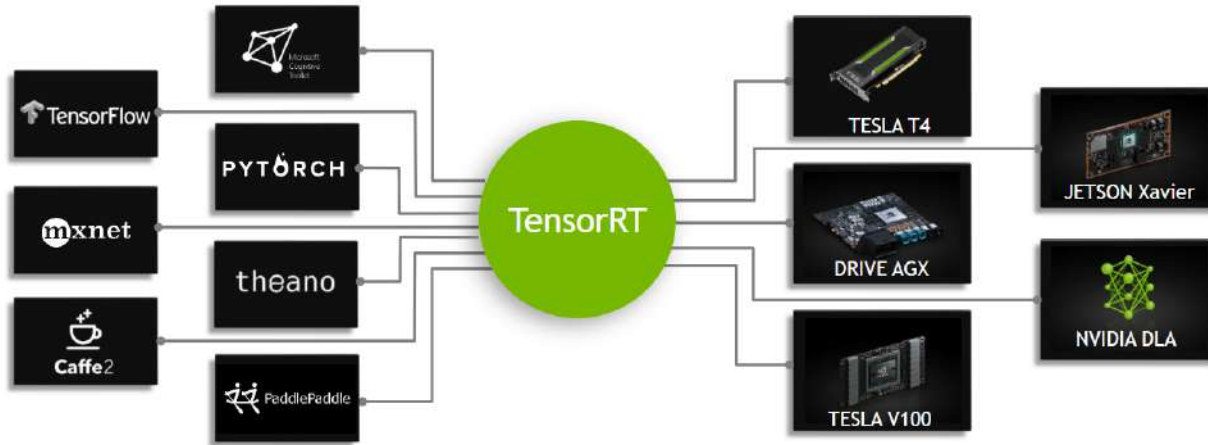
## Detectron





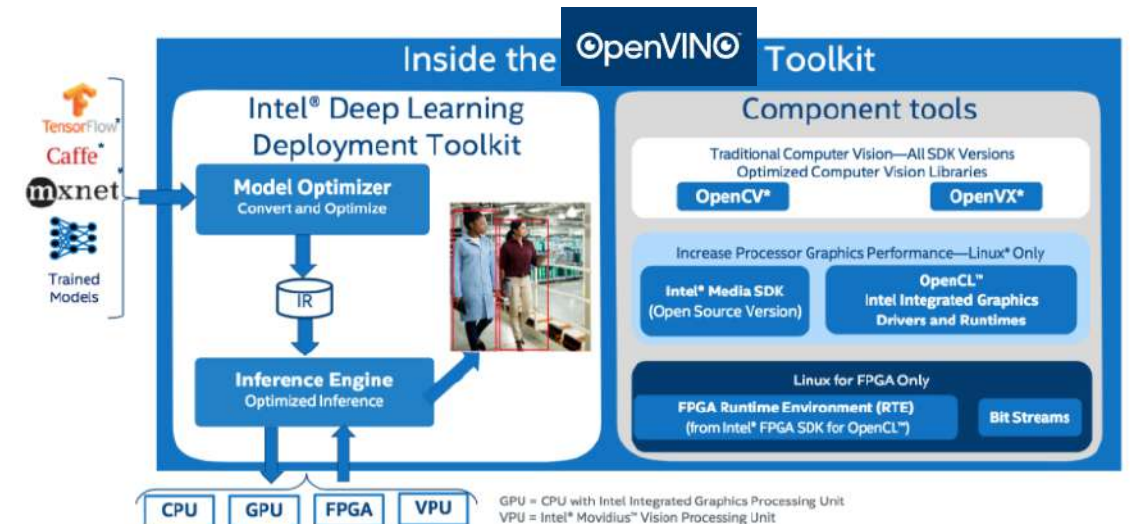
# Inference acceleration

## GPU



- 40x faster than CPU
- Model Zoo

## CPU



- 20x faster than CPU
- Model optimization
- Model Zoo

# Clouds for training

Colab.google



- <https://colab.research.google.com>
- 12h session
- Notebooks saved to google drive
- Not full jupyter keyboard shortcuts


Kaggle kernels

## kaggle

- <https://www.kaggle.com/notebooks>
- 9h session
- Notebooks easy savings
- Full jupyter keyboard shortcuts

# Preprocessing and augmentations

- [Albumentations](#)
- FastAI preprocessing
- Kornia [augmentations](#)
- [NVIDIA DALI](#) (on GPU)



# Acknowledgments

---

- Презентация подготовлена на основе слайдов Andrej Karpathy, Артура Кузина, Антона Конушина, Андрея Фильченкова, Всеволода Коняхина

# ВОПРОСЫ? ПИШИТЕ

Наталья Ханжина  
@natkaha



Роман Лебедев  
@lebedev\_rv

